

O modelo de classificação desenvolvido mostrou desempenho consistente na tarefa de prever a presença de doenças cardíacas a partir dos atributos clínicos do conjunto de dados. Após a padronização das variáveis — etapa fundamental devido às diferentes escalas dos atributos — a rede neural apresentou aprendizado estável, com convergência progressiva durante o treinamento.

No conjunto de teste, o modelo alcançou **acurácia aproximada de 80%**, juntamente com métricas de **precisão, recall e F1-score equilibradas** entre as duas classes. Esses valores indicam que, embora o desempenho não seja perfeito, o modelo consegue generalizar de forma satisfatória para novos dados.

A **matriz de confusão** evidencia um equilíbrio entre acertos e erros, com uma quantidade moderada de falsos positivos e falsos negativos. Em contextos médicos, tais erros devem ser interpretados com cautela, reforçando que o classificador atua como ferramenta de apoio e não como substituto de avaliação especializada.

As técnicas de regularização empregadas — como dropout — ajudaram a reduzir o risco de overfitting, embora seja possível observar uma **pequena divergência entre as curvas de perda de treino e teste**, indicando que ainda há espaço para melhorias na robustez do modelo.

No geral, o estudo reforça a importância da normalização das features, da análise exploratória e da escolha adequada da arquitetura da rede neural em aplicações clínicas. Mesmo com uma acurácia em torno de 80%, o modelo demonstra potencial como ferramenta auxiliar na identificação de padrões relevantes associados ao risco de doença cardíaca.